

Проект по количественной аналитике: разработка алгоритмических стратегий

Проект состоит из двух независимых частей по построению моделей машинного обучения на ежедневных и высокочастотных данных.

Часть 1: Модель машинного обучения на ежедневных данных

Постановка задачи

Ваша задача – попытаться построить модель, которая будет способна предсказать направление движения актива на рынке на следующий день на основании извлеченных вами признаков. На выбор можно взять либо биржевые инструменты, либо криптовалюты.

В качестве **входных данных** модель будет использовать временные ряды активов. Чтобы было удобнее с ними работать, мы ограничим интервалы времени, доступные на вход модели 30-ю днями (см. схему препроцессинга данных). Используя значения цен на этих интервалах, вам предстоит извлечь различные признаки. Одной из групп признаков должны стать результаты кластерного анализа временных рядов. Например, вы можете использовать метку кластера и любые другие статистики, которые вы посчитаете нужным, в качестве входных данных.


В качестве **целевой переменной** вам необходимо для каждого 30-дневного интервала взять значения цены на следующий день и посчитать, в какую сторону она изменилась по сравнению с предыдущим днем. В зависимости от волатильности ваших временных рядов, выберите некоторый процент изменения цены, в интервале которого вы будете считать цену актива стабильной, например, от -5% до +5%.

Описание задачи

1. **Сбор данных:** Собрать временные ряды финансовых данных (среднюю цену или цену закрытия) с частотой один час за последние 180 дней для 100+ различных тикеров акций или криптовалют. Если в выбранном API 180 дней с часовой частотой не доступны, выбрать максимально доступный диапазон.
2. **Формирование окон:** Разделить данные на окна длительностью 30 дней (720 точек) с использованием скользящего окна с дневной частотой, отложить часть данных для тестирования
3. **Кластеризация окон:** Для полученных окон на тренировочной выборке построить модели кластеризации временных рядов и выбрать одну, которую вы будете использовать в дальнейшем для извлечения признаков
4. **Создание признаков:** Извлечь значимые признаки из каждого окна, используя различные методы, включая статистические показатели и информацию о кластерах.
5. **Разметка данных:** Определить целевую переменную для каждого окна в зависимости от тренда на следующий день (рост, снижение, стабильность).

6. **Обучение модели:** Построить и обучить модель классификации для прогнозирования меток (рост, снижение, стабильность) на основе извлеченных признаков.
7. **Оценка модели:** Оценить точность модели с использованием тестовых данных.

Схема препроцессинга данных:



Материалы и навыки, необходимые для выполнения проекта

1. Умение работать в Python с API поставщиков финансовых данных
 - a. Для акций очень удобно использовать [API Yahoo Finance](#):

```
import yfinance as yf
data = yf.download('AAPL', period='6mo', interval='1h')
```
 - b. Для криптовалют есть бесплатный [CoinGecko](#), но часовые данные ограничены временным интервалом в 90 дней:

```
from pycoingecko import CoinGeckoAPI
cg = CoinGeckoAPI()
data = cg.get_coin_market_chart_by_id(id='bitcoin', vs_currency='usd', days=90)
```
2. Умение работать с моделями машинного обучения (подготовка тренировочных и тестовых данных, кластеризация, классификация, оценка качества моделей)
3. Извлечение признаков из временных рядов: [\[Ссылка на GitHub\]](#), [\[Ссылка на YouTube\]](#)
4. Кластеризация временных рядов: [\[Ссылка на GitHub\]](#), [\[Ссылка на YouTube\]](#)

Часть 2. Модель машинного обучения на высокочастотных данных

Задание 0. Разобраться со структурой маркет даты, понять, что такое ордербук и трейды.

Задание 1. Подумать, что может являться таргетом в этой задаче. Что мы можем взять за справедливую цену, которую хотим предсказать. Может быть цену из будущего, может быть изменение цены или что-то другое. Сгенерировать таргет.

Задание 2. Подумать, что может являться правильной метрикой для оценки данной задачи? Это задача классификации или регрессии? Написать метрику для оценки таргета.

Задание 3. Реализовать как можно больше качественных и осознанных фичей для решения этой задачи. В помощь статья с кучей фичей и видео, где рассказывают про способы предсказания рынка.

Задание 4. Реализовать и обучить модель машинного обучения и измерить скор по собственной метрике из задания 2. Таргет используется из задания 1.

Данные для модели (MD.zip):

<https://drive.google.com/file/d/1DiP5arvCEMxLHZ0R2mAS4lcMjnPHSrEJ>